

Esonero Laboratorio di Ingegneria Informatica 2026

Lorenzo Castelli
2115498

Ludovica Fiocchetta
2103669

Alessandro Genovese
2108670

1 Introduzione

Il progetto ha come obiettivo principale l'estrazione automatizzata di testo pulito dalle pagine di quattro domini internet tramite la libreria **Crawl4AI**, e la successiva valutazione dell'accuratezza dei parser, mediante il confronto tra il testo estratto dal crawler e il **gold standard** di riferimento creato manualmente.

I domini di riferimento sono:

- en.wikipedia.org
- www.viaggi-usa.it
- www.cbsnews.com
- www.cnbc.com

2 Organizzazione del codice

Il progetto è strutturato seguendo un'architettura a microservizi, separando nettamente la logica di estrazione e valutazione dei dati (**Backend**) dall'interfaccia utente (**Frontend**). L'intero sistema è containerizzato mediante Docker, tramite le specifiche in `docker-compose.yaml` per garantire la portabilità e riproducibilità dell'ambiente di esecuzione.

2.1 Backend

Il backend, esposto sulla porta 8003, è stato sviluppato in Python seguendo un'architettura modulare che si articola in tre macro-componenti fondamentali:

- **Validazione Dati e Server (server.py):** Questo modulo espone i servizi verso il **Frontend** sfruttando il framework **FastAPI**. Implementa l'interfaccia **REST API** e utilizza modelli **Pydantic** per la validazione rigorosa dei dati in ingresso e in uscita, assicurando che ogni endpoint (`/parse`, `/domains`, `/gold_standard`, ecc.) rispetti le specifiche di schema richieste. La logica di routing smista dinamicamente le richieste ai diversi parser in base al dominio dell'URL fornito.

- **Pipeline di Parsing (crawler_test*.py):**

Ogni dominio è gestito da un modulo dedicato che implementa una pipeline di estrazione a tre stadi basata sulla libreria **Crawl4AI**:

1. *Configurazione e Acquisizione:* Viene utilizzato `BrowserConfig` in modalità `headless` e `CrawlerRunConfig` con `CacheMode.BYPASS` per garantire l'acquisizione in tempo reale del contenuto. Se viene specificata in input una stringa `html`, viene invece svolta l'estrazione staticamente da quest'ultima senza interrogazione web.
2. *DOM Cleaning tramite JavaScript:* Prima della conversione in `Markdown`, viene iniettato codice **JavaScript** (`js_code`) per manipolare il DOM e rimuovere selettivamente elementi di disturbo come `infobox`, `sidebar`, `footer` e `banner pubblicitari`.
3. *Post-processing Regex:* Il testo convertito in `Markdown` viene ulteriormente filtrato tramite **espressioni regolari** per eliminare residui di tag, metadati, riferimenti bibliografici e spazi bianchi ridondanti, restituendo un testo pulito pronto per l'analisi.

- **accuracy.py:** Questo modulo funge da motore di valutazione del sistema. È stato progettato come un servizio indipendente che riceve stringhe di testo (estratto e di riferimento) e calcola il grado di sovrapposizione tra i set di token, operando una normalizzazione preventiva (lowercase e rimozione della punteggiatura) per garantire l'oggettività del confronto.

2.2 Frontend

L'interfaccia utente è stata progettata per fornire un punto di accesso intuitivo alle funzionalità del sistema. Il modulo è esposto sulla porta 8004 e si

compone delle seguenti parti:

- **frontend.py**: Sviluppato con **FastAPI**, questo modulo agisce come un'interfaccia tra l'utente e il backend. Utilizza il client asincrono **httpx** per comunicare internamente con i servizi del backend, recuperando dinamicamente la lista dei domini supportati e gli URL presenti nel Gold Standard per popolare l'interfaccia all'avvio. Gestisce l'intero ciclo di richiesta-risposta: coordina l'estrazione del testo per qualsiasi URL compatibile e, qualora la risorsa sia presente nel dataset di riferimento, innesca automaticamente il recupero e la visualizzazione delle metriche di valutazione.
- **templates/**: La presentazione dei dati è affidata a template HTML che utilizzano il motore di rendering **Jinja2** per la generazione dinamica dei contenuti. Grazie a Jinja2, l'interfaccia è in grado di adattarsi ai dati ricevuti: mostra messaggi di errore contestuali, popola i menu a tendina per i test rapidi e organizza i risultati dell'estrazione in una struttura a due colonne per facilitare il confronto tra Gold Standard e Markdown.
- **static/**: Questa directory contiene il foglio di stile **CSS** che definisce l'estetica dell'applicazione.

2.3 Dati e Configurazione

- **domains.json**: File di configurazione che elenca i domini target.
- **gs_data/**: Contiene i file JSON di Gold Standard necessari per il calcolo delle metriche di accuratezza.

3 Valutazione parser

La qualità dei parser è stata misurata confrontando l'output testuale ottenuto da ogni dominio con i dati di riferimento contenuti nella cartella `gs_data/` (Gold Standard).

3.1 Metodologia di valutazione

Nel modulo `accuracy.py`, oltre alla valutazione obbligatoria *token-level* (Precision, Recall e F1-score) basata sull'intersezione degli insiemi di parole, sono state implementate tre metriche avanzate (`x_eval`) per ottenere un'analisi più robusta:

- **Jaccard Similarity**: Valuta la similarità tra due insiemi testuali calcolando il rapporto tra la dimensione della loro intersezione e la dimensione della loro unione ($|A \cap B| / |A \cup B|$).

Rispetto all'F1-score, penalizza in modo più severo l'aggiunta di rumore (falsi positivi) combinata alla perdita di testo (falsi negativi), fornendo un indicatore molto rigoroso della sovrapposizione del vocabolario.

- **Bigram Overlap**: Calcola la sovrapposizione di coppie di parole consecutive (bigrammi). È fondamentale per verificare se la struttura sintattica locale e l'ordine logico delle frasi sono stati preservati durante il parsing, penalizzando rimescolamenti o frammentazioni eccessive del testo estratto.
- **Cosine Similarity**: Misura l'affinità semantica trasformando i documenti in vettori matematici. Attraverso il modello TF-IDF (*Term Frequency-Inverse Document Frequency*), ogni termine riceve un peso basato sulla sua importanza relativa nel testo. La metrica calcola geometricamente il coseno dell'angolo formato dal vettore del testo parsato e quello del Gold Standard. Questa interpretazione vettoriale rende la metrica robusta per valutare se i documenti sono focalizzati sugli stessi concetti chiave, ignorando le piccole variazioni di punteggiatura o stop-words.

3.2 Risultati ottenuti

Nelle Tabelle sono riportati i risultati medi ottenuti per ciascun dominio target sull'intero Gold Standard, generati tramite l'endpoint `/full_gs_eval`. I valori permettono di quantificare oggettivamente l'efficacia dei parser.

Dominio	Precision	Recall	F1-score
en.wikipedia.org	0.9979	0.9989	0.9984
www.cbsnews.com	1.0000	1.0000	1.0000
www.cnn.com	0.9995	0.9985	0.9990
www.viaggi-usa.it	0.9919	0.9989	0.9953

Dominio	Jaccard S.	Bigram O.	Cosine S.
en.wikipedia.org	0.9969	0.9983	0.9998
www.cbsnews.com	1.0000	1.0000	0.9999
www.cnn.com	0.9981	0.9992	0.9986
www.viaggi-usa.it	0.9909	0.9976	0.9988

Table 1: Metriche di accuratezza Token-level (sopra) e metriche avanzate (sotto) ottenute dai parser per dominio.