

Esonero Laboratorio di Ingegneria Informatica 2026

Lorenzo Castelli
2115498

Ludovica Fiocchetta
2103669

Alessandro Genovese
2108670

1 Introduzione

Il progetto ha come obiettivo principale l'estrazione automatizzata di testo pulito dalle pagine di quattro domini internet tramite la libreria **Crawl4AI**, e la successiva valutazione dell'accuratezza dei parser, mediante il confronto tra il testo estratto dal crawler e il **gold standard** di riferimento creato manualmente.

I domini di riferimento sono:

- en.wikipedia.org
- www.viaggi-usa.it
- www.cbsnews.com
- www.cnbc.com

2 Organizzazione del codice

Il progetto è strutturato seguendo un'architettura a microservizi, separando nettamente la logica di estrazione e valutazione dei dati (**Backend**) dall'interfaccia utente (**Frontend**). L'intero sistema è containerizzato mediante Docker e orchestrato tramite `docker-compose.yaml` per garantire la portabilità e riproducibilità dell'ambiente di esecuzione.

2.1 Backend

Il backend, esposto sulla porta 8003, rappresenta il cuore logico dell'intero sistema. È stato sviluppato in Python seguendo un'architettura modulare che garantisce una netta separazione delle responsabilità. Il codice si articola in tre macro-componenti fondamentali:

- **Validazione Dati e Server (`server.py`):** Questo modulo espone i servizi all'esterno sfruttando il framework **FastAPI**, scelto per le alte prestazioni e la gestione nativa dell'asincronia. Implementa l'interfaccia **REST API** e utilizza modelli **Pydantic** per la validazione rigorosa dei dati in ingresso e in uscita, assicurando che ogni endpoint (`/parse`, `/domains`, `/gold_standard`, ecc.)

rispetti le specifiche di schema richieste. La logica di routing smista dinamicamente le richieste ai diversi parser in base al dominio dell'URL fornito.

- **Pipeline di Parsing (`crawler_test_*.py`):** Ogni dominio è gestito da un modulo dedicato che implementa una pipeline di estrazione a tre stadi basata sulla libreria **Crawl4AI**:

1. *Configurazione e Acquisizione:* Viene utilizzato `BrowserConfig` in modalità `headless` e `CrawlerRunConfig` con `CacheMode.BYPASS` per garantire l'acquisizione in tempo reale del contenuto.
2. *DOM Cleaning via JavaScript:* Prima della conversione in Markdown, viene iniettato codice **JavaScript** (`js_code`) per manipolare il DOM e rimuovere selettivamente elementi di disturbo come infobox, sidebar, footer e banner pubblicitari.
3. *Post-processing Regex:* Il testo convertito in Markdown viene ulteriormente raffinato tramite **espressioni regolari** per eliminare residui di tag, metadati, riferimenti bibliografici e spazi bianchi ridondanti, restituendo un testo pulito pronto per l'analisi.

- **`accuracy_tester.py`:** Questo modulo funge da motore di valutazione del sistema. È stato progettato come un servizio indipendente che riceve stringhe di testo (estratto e di riferimento) e calcola il grado di sovrapposizione tra i set di token, operando una normalizzazione preventiva (lowercase e rimozione della punteggiatura) per garantire l'oggettività del confronto.

2.2 Frontend

L'interfaccia utente è stata progettata per essere un punto di accesso semplificato alle funzionalità del

sistema. Il modulo è esposto sulla porta 8004 e si compone delle seguenti parti:

- **frontend.py**: Sviluppato con **FastAPI**, questo modulo agisce come un'interfaccia tra l'utente e il backend. Utilizza il client asincrono **httpx** per comunicare internamente con i servizi del backend, recuperando dinamicamente la lista dei domini supportati e le URL presenti nel Gold Standard per popolare l'interfaccia all'avvio. Gestisce il ciclo di richiesta-risposta per l'analisi delle URL, coordinando il recupero del testo parsato e delle relative metriche di valutazione.
- **templates/**: La presentazione dei dati è affidata a template HTML che utilizzano il motore di rendering **Jinja2** per la generazione dinamica dei contenuti. Grazie a Jinja2, l'interfaccia è in grado di adattarsi ai dati ricevuti: mostra messaggi di errore contestuali, popola i menu a tendina per i test rapidi e organizza i risultati dell'estrazione in una struttura a due colonne per facilitare il confronto tra Gold Standard e Markdown.
- **static/**: Questa directory contiene il foglio di stile **CSS** che definisce l'estetica dell'applicazione.

2.3 Dati e Configurazione

- **domains.json**: File di configurazione che elenca i domini target.
- **gs_data/**: Contiene i file JSON di Gold Standard necessari per il calcolo delle metriche di accuratezza.

3 Valutazione parser

La qualità dei parser è stata misurata confrontando l'output testuale ottenuto da ogni dominio con i dati di riferimento contenuti nella cartella `gs_data/` (Gold Standard).

3.1 Metodologia di valutazione

Nel modulo `accuracy_tester.py`, oltre alla valutazione obbligatoria *token-level* (Precision, Recall e F1-score) basata sull'intersezione degli insiemi di parole, sono state implementate tre metriche avanzate (`x_eval`) per ottenere un'analisi più robusta:

- **Jaccard Similarity**: Valuta la similarità tra due insiemi testuali calcolando il rapporto tra la dimensione della loro intersezione e la dimensione della loro unione ($|A \cap B| / |A \cup B|$). Rispetto all'F1-score, penalizza in modo più

severo l'aggiunta di rumore (falsi positivi) combinata alla perdita di testo (falsi negativi), fornendo un indicatore molto rigoroso della sovrapposizione del vocabolario.

- **ROUGE-L (Longest Common Subsequence)**: A differenza delle metriche insiemistiche *bag-of-words*, ROUGE-L tiene conto dell'ordine e della sequenzialità delle parole. Identifica la più lunga sottosequenza comune tra il testo estratto e il Gold Standard. Questa metrica è fondamentale per verificare se la struttura sintattica originale e l'ordine delle frasi sono stati preservati durante il parsing, penalizzando frammentazioni eccessive.
- **Cosine Similarity (TF-IDF)**: Misura l'affinità semantica vettorializzando i documenti. Attraverso il modello TF-IDF (*Term Frequency-Inverse Document Frequency*), ogni termine riceve un peso basato sulla sua importanza relativa nel testo. Calcolando il coseno dell'angolo tra i due vettori risultanti, questa metrica valuta se i due testi sono focalizzati sugli stessi concetti chiave, dimostrandosi resiliente a piccole variazioni di punteggiatura o stop-words.

3.2 Risultati ottenuti

Nelle Tabelle sono riportati i risultati medi ottenuti per ciascun dominio target sull'intero Gold Standard, generati tramite l'endpoint `/full_gs_eval`. I valori di F1-score e delle metriche avanzate permettono di quantificare oggettivamente l'efficacia dei parser nel filtrare il boilerplate (come menu e pubblicità) mantenendo intatto il contenuto informativo.

Dominio	Precision	Recall	F1-score
en.wikipedia.org	0.9979	0.9989	0.9984
www.cbsnews.com	1.0000	1.0000	1.0000
www.cnn.com	0.9995	0.9985	0.9990
www.viaggi-usa.it	0.9919	0.9989	0.9953

Dominio	Jaccard S.	ROUGE-L	Cosine S.
en.wikipedia.org	0.9969	0.9975	0.9998
www.cbsnews.com	1.0000	1.0000	0.9999
www.cnn.com	0.9981	0.9929	0.9986
www.viaggi-usa.it	0.9909	0.9951	0.9988

Table 1: Metriche di accuratezza Token-level (sopra) e metriche avanzate (sotto) ottenute dai parser per dominio.